



中山大學
SUN YAT-SEN UNIVERSITY

多模态大模型原理与应用课程报告

基于视觉理解与自动操作的智能浏览器助手

姓名 _____

学号 _____

学院 _____ 计算机学院

专业 _____ 计算机科学与技术

目录

一 实验评测与分析	2
1 HTML 输入模式下的性能测评	3
2 SoM 输入模式下的性能测评	3

一 实验评测与分析

针对项目模型的 SoM 输入与 HTML 输入模式分别设计了评测实验。所有本地模型均在一台 RTX 3090 24GB ×1, 内存 60GB 的计算机上运行, 并使用 Qwen 3VL-8B-Instruct 作为本地测试模型, 使用 API 调用 Qwen3.7-max 测试。选取任务成功率 (SR)、元素准确率 (Ele. Acc)、任务单步操作的 F1 分数 (Op.F1)、任务单步成功率 (Step SR) 以及单步平均耗时作为评价 Web Agent 性能的标准。其中, Ele. Acc 表示各任务内选择正确网页元素的步数比例跨任务的均值, Op.F1 分数表示单步操作的 F1 值, Step SR 表示各任务内元素与操作均正确的步数比例跨任务的均值, SR 表示所有步骤均成功执行的任务数占数据集总任务数的比例。

$$\text{Ele.Acc} = \frac{1}{M} \sum_{i=1}^M \frac{1}{N_i} \sum_{j=1}^{N_i} \mathbb{I}(\hat{e}_{i,j} \in S_{acc}(e_{i,j}))$$

$$\text{Op.F1}_{i,j} = \mathbb{I}(\hat{op}_{i,j} \in S_{op}(op_{i,j})) \times \begin{cases} 1 & op_{i,j} = \text{CLICK} \\ \text{F1}(v_{i,j}, \hat{v}_{i,j}) & op_{i,j} \in \{\text{TYPE}, \text{SELECT}\} \end{cases}$$

$$\text{Step SR} = \frac{1}{M} \sum_{i=1}^M \frac{1}{N_i} \sum_{j=1}^{N_i} \left[\mathbb{I}(\hat{e}_{i,j} \in S_{acc}(e_{i,j})) \times \mathbb{I}(\text{Op.F1}_{i,j} = 1) \right]$$

$$\text{SR}_i = \prod_{j=1}^{N_i} \left[\mathbb{I}(\hat{e}_{i,j} \in S_{acc}(e_{i,j})) \times \mathbb{I}(\text{Op.F1}_{i,j} = 1) \right]$$

其中 M 为数据集内的总任务数, N_i 为第 i 个任务的步骤数, $e_{i,j}, \hat{e}_{i,j}$ 分别为第 i 个任务第 j 步中 Ground Truth 的等价网页元素集合和 Agent 预测的网页元素, $op_{i,j} \in \{\text{CLICK}, \text{TYPE}, \text{SELECT}\}$ 为 Ground Truth 操作类型, $\hat{op}_{i,j}$ 为预测操作类型, $v_{i,j}, \hat{v}_{i,j}$ 分别为 Ground Truth 和预测的操作值。 $S_{op}(\text{CLICK}) = \{\text{CLICK}, \text{HOVER}, \text{PRESS}\}$ 为 Mind2Web 中将 HOVER 和 PRESS_ENTER 映射至 CLICK 的等价操作集合; $\text{F1}(\cdot, \cdot)$ 为 F1 分数。

1. HTML 输入模式下的性能测评

选用 Mind2Web 数据集对模型进行评测。Mind2Web 数据集是一个大规模的 Web Agent 基准数据集, 将真实世界的静态网页作为数据, 具有 1,341 个不同任务和 46 步的最长任务步数, 在 Web Agent 领域被广泛用于测试模型的页面理解与执行能力。

我们对 Mind2Web 数据集提供的评测方法进行了修改。在 Mind2Web 数据集提供的 HTML 应用过滤规则只保留可交互元素后, 使用一个基于 Bert2 实现的预训练模型 all-MiniLM-L6-v2 对剩余候选元素进行排序并交给 VLM 进行选择, 并给出对应的操作类型和元素, 最后计算 Ele. Acc, OP.F1, Step SR 和 SR。

表 1: HTML 输入模式下模型在 Mind2Web 数据集上的性能

	Cross-Task				Cross-Website				Cross-Domain				Time(s)
	EA	OP	SS	SR	EA	OP	SS	SR	EA	OP	SS	SR	
Qwen3-VL-8B	41.9	84.0	33.9	1.5	32.0	78.0	26.4	1.0	36.0	83.0	28.0	3.0	1.3
Qwen3.7-max	64.6	80.5	52.0	8.7	57.9	81.3	42.4	6.2	55.6	81.9	43.8	7.3	14.3

由表 1 可以看出, Qwen3.7-max 在元素定位上显著优于 Qwen3-VL-8B, 元素准确率平均比 Qwen3-VL-8B 提高了 22.7%, 最终导致更高的单步成功率与任务成功率。但 Qwen3-VL-8B 作为小模型具有快速响应与低成本的优势, 在相对较好的网页操作性能和较快的响应时间中取得了平衡。Qwen3.7-max 的参数量过大, 虽然准确率更高但响应时间是 Qwen3-VL-8B 的 11 倍, 不具有实时性。

2. SoM 输入模式下的性能测评

为评估 SoM 视觉输入模式在真实网页场景下的表现, 自行设计了包含 30 个任务的测试集, 全部基于可公开访问的真实网站。测试任务覆盖多种难度与应用场景, 代表性任务包括: 搜索”中山大学广州校区南校园”并返回地址、打开哔哩哔哩首页点击第一个视频后返回作者头像、登录 QQ 邮箱并向指定地址发送端午祝福邮件等。完整任务列表见附录。所有测试均使用 Qwen 3VL-8B-Instruct 模型, 在有头浏览器模式下运行, 每个任务至少重复运行 3 次以减小随机性。

由于自建测试集缺少 Mind2Web 数据集中的 Ground Truth 标注 (如真实操作序列和正负候选元素), 无法直接计算 Ele. Acc 和 Op.F1 等微观指标。因此针对真实网页场景,

定义以下两项宏观指标评价 Agent 的任务完成能力：

$$SR = \frac{S}{N}$$

$$AvgSteps = \frac{1}{S} \sum_{i \in S} steps_i$$

其中 $N = 30$ 为测试任务总数， S 为成功完成（Agent 返回正确答案且人工验证通过）的任务数， $\mathcal{S}$ 为成功任务集合， $steps_i$ 为第 i 个任务成功完成时使用的步数。

表 2: SoM 输入模式与 HTML 输入模式在自建测试集上的对比

模型	SoM 输入		HTML 输入	
	SR	AvgSteps	SR	AvgSteps
Qwen 3VL-8B	73.3	10.5	40.0	6.8

由表 2 可以看出，SoM 视觉输入模式相比 HTML 文本输入模式在真实网页任务上具有显著优势。任务成功率从 40.0% 提升至 73.3%，提升幅度达 83.3%。分析任务完成情况发现，HTML 输入模式能够成功完成的任务以简单的搜索引擎查询为主（如事实类搜索、天气查询等），一旦任务涉及表单填写、页面跳转、多步交互等复杂操作，成功率显著下降。SoM 模式由于能够直观地识别页面布局与元素空间位置，在需要点击特定按钮、填写表单、切换标签页等复杂操作时表现更好。但 SoM 模式的完成任务平均步数 10.5 步明显高于 HTML 模式的 6.8 步，这一方面是因为 SoM 模式成功完成的任务本身更复杂，自然需要更多操作步数；另一方面也与 SoM 模式下模型倾向于执行更多探索性操作（如下拉滚动、尝试不同元素）有关。

总体而言，SoM 输入模式以更多的操作步数为代价，换取了更高的任务完成率与更广泛的任务适用性，在真实网页场景下优于 HTML 文本输入模式。