




中山大學
SUN YAT-SEN UNIVERSITY

VisuMark Agent

——基于视觉理解与自动操作
的智能浏览器助手


邱恺铭 饶鹏程 刘德凯



2026/5/6

Sun Yat-Sen University

WebAgent



在多模态大模型技术成熟的背景下，基于VLM/LLM技术实现的多模态网页Agent能够实现辅助和某种程度地替代人类完成对应的网页任务，具有广阔的应用前景。

我们计划实现一个能够理解自然语言指令，并通过浏览器自主完成复杂任务的智能代理。

- SoM 标记模块：为每个可交互元素分配唯一编号，在截图上绘制彩色边界框和数字，输出“带标记的截图”。
- 决策层：输入用户自然语言指令 + 带标记的截图，输出结构化动作。
- 执行器：根据决策模型输出的标记编号，查找对应的元素，调用精确的浏览器操作。
- 验证与反馈：执行后重新截图并生成新的 SoM 标记图。
- 状态管理：维护动作历史、最大步数限制、重试计数器。




图 1: 系统架构图

表 1: 模型选择与算力分配

模块	方案	推理成本/设备
SoM标记生成	SAM等相关模块	CPU，无GPU需求
决策模型（VLM）	Qwen3-VL-8B-Instruct	约12-16GB GPU
坐标定位与执行	Playwright内置定位器 + 可访问树	无需额外模型
失败处理	规则回退 + VLM再次识图	少量额外调用

总 GPU 需求：一块 24GB 显存的消费级显卡（如 RTX 3090/4090）用于部署 VLM。云端 API 作为备份或加速方案。

Ele.Acc：所有步骤中选择正确网页元素的步数所占的比例。

Op.F1：单步操作的准确程度。

Step SR：数据集所有步骤中成功的单步步骤所占的比例。

SR：执行成功的任务数占数据集中任务总数的比例。

$$\text{Ele.Acc} = \frac{1}{\sum_{i=1}^M N_i} \sum_{i=1}^M \sum_{j=1}^{N_i} \mathbb{I}(e_{i,j} \in S_{acc}(\hat{e}_{i,j}))$$

$$\text{Op.F1}_{i,j} = \begin{cases} 1 & \text{if } op_{\text{type}} \text{ is 'Click'} \\ \text{F1}(v_{i,j}, \hat{v}_{i,j}) & \text{if } op_{\text{type}} \text{ is 'Type' or 'Select'} \end{cases}$$

$$\text{Step SR} = \frac{1}{\sum_{i=1}^M N_i} \sum_{i=1}^M \sum_{j=1}^{N_i} [\mathbb{I}(e_{i,j} \in S_{acc}(\hat{e}_{i,j})) \times \mathbb{I}(\text{Op.F1}_{i,j} = 1)]$$

$$\text{SR}_i = \prod_{j=1}^{N_i} (\mathbb{I}(e_{i,j} \in S_{acc}(\hat{e}_{i,j})) \times \mathbb{I}(\text{Op.F1}_{i,j} = 1))$$

表 2: 时间计划

阶段	预计耗时
环境搭建与Playwright基础测试	第1周
SoM标记模块开发（可访问树解析+图像标注）	第2周
单VLM（Qwen3-VL-8B-Instruct）本地部署与接口封装	第3周
决策模型与执行器集成（映射表+动作解析）	第4周
闭环验证与重试机制开发	第5-6周
完整60次自动化测试及数据收集	第7周
错误分析、轨迹可视化与报告撰写	第8周

- [1] Xiang Deng, Yu Gu, Boyuan Zheng, Shijie Chen, Sam Stevens, Boshi Wang, Huan Sun, and Yu Su. Mind2Web: Towards a generalist agent for the web. In A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine, editors, Advances in Neural Information Processing Systems, volume 36. Curran Associates, Inc., 2023. URL https://proceedings.neurips.cc/paper_files/paper/2023/file/5950bf290a1570ea401bf98882128160-Paper-Datasets_and_Benchmarks.pdf.
- [2] Hiroki Furuta, Kuang-Huei Lee, Offr Nachum, Yutaka Matsuo, Aleksandra Faust, Shixiang Shane Gu, and Izzeddin Gur. Multimodal web navigation with instructionffnetuned foundation models. arXiv preprint arXiv:2305.11854, 2023.
- [3] Hongliang He, Wenlin Yao, Kaixin Ma, Wenhao Yu, Yong Dai, Hongming Zhang, Zhenzhong Lan, and Dong Yu. WebVoyager: Building an end-to-end web agent with large multimodal models. In Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pages 6864– 6890, 2024.
- [4] Shyam Sundar Kannan, Vishnunandan L. N. Venkatesh, and Byung-Cheol Min. SMART-LLM: Smart multi-agent robot task planning using large language models. In 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pages 12140–12147, 2024. doi: 10.1109/IROS58592.2024.10802322.
- [5] Xinyi Li, Sai Wang, Siqi Zeng, Yu Wu, and Yi Yang. A survey on LLM-based multi-agent systems: workffow, infrastructure, and challenges. Vicinagearth, 1(1), October 2024. ISSN 3005-060X. doi: 10.1007/s44336-024-00009-2. URL <http://dx.doi.org/10.1007/s44336-024-00009-2>.
- [6] Microsoft. Playwright: Fast and reliable cross-browser automation, 2025. URL <https://playwright.dev/>.
- [7] Microsoft Research. Fara-7B: A foundation model for GUI automation. Technical report, Microsoft, 2025.
- [8] OpenClaw Contributors. OpenClaw: Open-source multimodal web agent, 2025. URL <https://github.com/openclaw/openclaw>.
- [9] Joonhyung Park, Peng Tang, Sagnik Das, Srikar Appalaraju, Kunwar Yashraj Singh, R. Manmatha, and Shabnam Ghadar. R-VLM: Region-aware vision language model for precise GUI grounding. In Wanxiang Che, Joyce Nabende, Ekaterina Shutova, and Mohammad Taher Pilehvar, editors, Findings of the Association for Computational Linguistics: ACL 2025, pages 9669–9685, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-256-5. doi: 10.18653/v1/2025. findings-acl.501. URL <https://aclanthology.org/2025.findings-acl.501/>.
- [10] Jianwei Yang, Hao Zhang, Feng Li, Xueyan Zou, Chunyuan Li, and Jianfeng Gao. Set-of-mark prompting unleashes extraordinary visual grounding in GPT-4V, 2023. URL <https://arxiv.org/abs/2310.11441>.



中山大學
SUN YAT-SEN UNIVERSITY

谢谢观看

Thanks